

# Rapport détaillé : Partie 2 — Prédiction du Cooling Load

Nom de l'auteur

30 novembre 2025

# Table des matières

|                                                  |   |
|--------------------------------------------------|---|
| 1. Introduction Générale . . . . .               | 2 |
| 2. Objectifs spécifiques . . . . .               | 2 |
| 3. Description complète du Dataset . . . . .     | 2 |
| 4. Préparation des données . . . . .             | 3 |
| 5. Modèle 1 : Régression Linéaire . . . . .      | 4 |
| 6. Modèle 2 : SVR . . . . .                      | 4 |
| 7. Comparaison des modèles . . . . .             | 4 |
| 8. Visualisations et Analyse Graphique . . . . . | 5 |
| 9. Conclusion . . . . .                          | 9 |

# 1. Introduction Générale

La consommation énergétique des bâtiments constitue un enjeu majeur dans le contexte de la transition énergétique et de la lutte contre le réchauffement climatique. Les bâtiments modernes représentent environ 30% de la consommation énergétique totale, dont une part importante est attribuée au chauffage et au refroidissement.

Le **Cooling Load** correspond à l'énergie nécessaire pour maintenir une température intérieure confortable durant les périodes chaudes. Il dépend de nombreux facteurs : conception architecturale, surface, hauteur du bâtiment, orientation, matériaux, et surface vitrée.

Cette partie du projet vise à développer et comparer des modèles de prédiction du Cooling Load basés sur le Machine Learning, afin d'améliorer la précision énergétique des bâtiments dès leur conception.

## 2. Objectifs spécifiques

### 2.1 Chargement et préparation des données

Les données ont été collectées et nettoyées afin d'assurer leur qualité. Cette étape comprend :

- Vérification de l'intégrité des données.
- Identification des anomalies ou valeurs aberrantes.
- Préparation des variables pour la modélisation.

### 2.2 Séparation des variables

Les variables sont classées en :

- **Variables explicatives (X)** : caractéristiques physiques du bâtiment.
- **Variable cible (y)** : Cooling Load.

### 2.3 Normalisation et division des données

- Normalisation des variables afin de standardiser les échelles.
- Division en ensemble d'entraînement (80%) et de test (20%).

### 2.4 Construction des modèles

Deux modèles sont étudiés :

- Régression Linéaire.
- Support Vector Regression (SVR) avec kernel RBF.

## 3. Description complète du Dataset

Le dataset contient 768 observations et 8 caractéristiques principales :

- Relative Compactness
- Surface totale
- Wall Area
- Roof Area

- Overall Height
  - Orientation
  - Glazing Area
  - Glazing Area Distribution
- Variable cible** : Cooling Load.

### 3.1 Analyse exploratoire préliminaire

Cette étape permet de détecter les relations entre les caractéristiques et les charges énergétiques.

### 3.2 Analyse Descriptive — Nuage de Points Entre la Charge de Chauffage et les Caractéristiques




FIGURE 1 – Nuage de points : Heating Load vs caractéristiques du bâtiment.

## 4. Préparation des données

### 4.1 Vérification des données

Aucune valeur manquante n'a été détectée. Les variables sont normalisées pour SVR.

### 4.2 Séparation des variables

Toutes les caractéristiques sauf Heating Load et Cooling Load sont utilisées comme variables explicatives.

### 4.3 Division train/test

Répartition : 80% pour l'entraînement et 20% pour le test.

## 5. Modèle 1 : Régression Linéaire

### 5.1 Hypothèses

- Relation linéaire.
- Homoscédasticité.
- Indépendance des erreurs.
- Normalité des résidus.

### 5.2 Analyse des résultats

- MSE et MAE élevés.
- $R^2 = 0.88$ .
- Incapacité à modéliser la non-linéarité des données.

## 6. Modèle 2 : Support Vector Regression (SVR)

### 6.1 Avantages

- Capture des relations non linéaires.
- Robustesse.
- Kernel RBF performant.

### 6.2 Analyse des résultats

- MSE et MAE très faibles.
- $R^2 = 0.98$ .

## 7. Comparaison des modèles

| Modèle              | MSE         | MAE         | $R^2$ |
|---------------------|-------------|-------------|-------|
| Régression Linéaire | Élevé       | Élevé       | 0.88  |
| SVR (RBF)           | Très faible | Très faible | 0.98  |

TABLE 1 – Comparaison des performances.

## 8. Visualisations et Analyse Graphique

### 8.1 Comparaison valeurs réelles / prédictions




FIGURE 2 – Comparaison des valeurs réelles avec les prédictions.




FIGURE 3 – Comparaison sur les 100 premiers points.

## 8.2 Analyse des résidus




FIGURE 4 – Résidus du modèle linéaire et du SVR.




FIGURE 5 – Boxplot des résidus.

## 8.3 Distribution des prédictions




FIGURE 6 – Distribution des prédictions SVR.

## 8.4 Analyse des corrélations




FIGURE 7 – Matrice de corrélation.



## 8.5 Résidus vs prédictions




FIGURE 8 – Résidus en fonction des prédictions.

## 8.6 Erreurs cumulées




FIGURE 9 – Erreurs cumulées.

## 8.7 Distribution valeurs réelles vs prédites




FIGURE 10 – Distribution des valeurs réelles vs prédites.

## 8.8 Comparaison des performances




FIGURE 11 – Comparaison graphique des performances.

## 9. Conclusion

Le SVR s'impose comme le meilleur modèle grâce à sa capacité à capturer la non-linéarité du dataset.

Perspectives :

- Optimisation des hyperparamètres.
- Ajout de modèles avancés : Random Forest, XGBoost, réseaux neuronaux.
- Interprétabilité (SHAP, LIME).