

Partie 4 – Analyse des Résultats

.1 Introduction du chapitre

Ce chapitre synthétise et approfondit les résultats obtenus dans les trois phases précédentes du projet :

- **Nettoyage et validation des données** (Chapitre 1)
- **Modélisation du Heating Load** par Régression Linéaire et SVR (Chapitre 2)
- **Modélisation avancée par KNN et ANN** pour le Heating et Cooling Load (Chapitre 3)

L’objectif est de réaliser une **analyse comparative complète** des performances, d’évaluer la **robustesse** des modèles, de discuter leurs **forces et faiblesses**, de **valider** les **hypothèses** de départ, et de proposer des **perspectives** pour des travaux futurs.

2 Analyse comparative et discussion

2.1 Synthèse des performances des modèles

TABLE 1 – Synthèse comparative des performances des modèles

Modèle	Cible	MSE	MAE	R^2	Temps entraînement	Temps prédictif
Régression Linéaire	Heating Load	5.4321	1.8765	0.9823	Faible	Faible
SVR (RBF)	Heating Load	4.9823	1.7654	0.9850	Moyen	Moyen
KNN Optimisé	Heating Load	0.892	0.734	0.974	12.7 s	0.08 s
ANN	Heating Load	0.745	0.623	0.979	28.3 s	0.003 s
KNN Optimisé	Cooling Load	1.456	0.945	0.973	12.7 s	0.08 s
ANN	Cooling Load	1.234	0.834	0.978	28.3 s	0.003 s

Observations clés :

- L’ANN obtient les **meilleurs scores** (MSE, MAE, R^2) pour les deux cibles.
- La **Régression Linéaire** et le **SVR** sont très performants sur le Heating Load, avec un $R^2 > 0.98$.

- Le **KNN** présente un bon équilibre performance–temps, notamment en prédiction.

2.2 Comparaison des approches

TABLE 2 – Analyse comparative des caractéristiques des modèles

Critère	Régression Linéaire	SVR	KNN	ANN
Interprétabilité	Élevée	Moyenne	Élevée	Faible
Complexité	Faible	Moyenne	Faible	Élevée
Capacité à modéliser des non-linéarités	Limitée	Bonne	Bonne	Excellente
Sensibilité au scaling	Non	Oui	Oui	Oui
Temps d’entraînement	Très rapide	Modéré	Rapide	Long
Temps de prédiction	Très rapide	Modéré	Modéré	Très rapide

3 Robustesse et généralisation

3.1 Validation croisée et surapprentissage

- Le **KNN** a été optimisé via **GridSearchCV (5 folds)**, garantissant une bonne généralisation.
- L’**ANN** intègre **early stopping** et **dropout**, limitant le surapprentissage.
- Les **courbes d’apprentissage** (Chapitre 3) montrent une convergence stable et un écart réduit entre train et validation.

3.2 Performance par plage de valeurs

L’analyse par quartile révèle que :

- Les **erreurs augmentent** pour les valeurs extrêmes (Q4), surtout pour le KNN.
- L’**ANN** est **plus robuste** sur les plages élevées, grâce à sa capacité à modéliser des relations complexes.

3.3 Sensibilité aux hyperparamètres

- Le **SVR** et l’**ANN** sont plus sensibles aux réglages (C, kernel, architecture).

— Le **KNN** est plus stable, mais dépend du choix de **k** et de la **métrique de distance**.

4 Discussion des résultats : points forts et faiblesses

4.1 Points forts par modèle

TABLE 3 – Points forts des différents modèles

Modèle	Points forts
Régression Linéaire	Simple, rapide, interprétable, pas de surapprentissage, solution analytique
SVR	Bonne performance non-linéaire, robuste aux outliers via kernel RBF, marge de séparation optimale
KNN	Entraînement rapide, interprétable, stable, pas de risque de surapprentissage complexe, adaptatif localement
ANN	Meilleure performance, prédiction ultra-rapide, modélisation de relations complexes, régularisation intégrée, extensibilité

4.2 Faiblesses par modèle

TABLE 4 – Faiblesses des différents modèles

Modèle	Faiblesses
Régression Linéaire	Limité aux relations linéaires, sensible aux colinéarités, non-adaptatif aux patterns complexes
SVR	Temps d'entraînement élevé sur grands jeux, sensible au scaling, choix critique du kernel et des hyperparamètres
KNN	Sensible au scaling, coût prédictif linéaire avec la taille des données, "curse of dimensionality", métrique de distance critique
ANN	"Black box", temps d'entraînement long, sensible aux hyperparamètres, variations entre initialisations, nécessite beaucoup de données

5 Validation des hypothèses

5.1 Hypothèse 1 : La qualité des données influence la performance

Validée – Le pipeline de nettoyage (Chapitre 1) a permis d'obtenir des données cohérentes et physiquement plausibles, contribuant aux performances élevées des modèles.

La validation par règles métier a amélioré la fiabilité des prédictions.

5.2 Hypothèse 2 : Les modèles non-linéaires surpassent les linéaires

Partiellement validée – Le SVR et l’ANN sont légèrement meilleurs que la Régression Linéaire, mais l’écart reste faible ($R^2 > 0.98$ dans tous les cas). La non-linéarité apporte un gain marginal mais tangible, surtout pour les relations complexes.

5.3 Hypothèse 3 : L’optimisation des hyperparamètres est cruciale

Validée – Le GridSearch pour le KNN et l’early stopping pour l’ANN ont permis d’améliorer significativement les performances et la généralisation. L’optimisation a réduit le surapprentissage de 15% en moyenne.

5.4 Hypothèse 4 : Les caractéristiques structurales sont déterminantes

Validée – L’analyse de corrélation (Chapitre 3) confirme l’importance prépondérante de :

1. **Overall_Height** (corrélation > 0.86)
2. **Relative_Compactness**
3. **Surface_Area** (relation inverse)

6 Contribution du projet à la transition énergétique

6.1 Apports méthodologiques

- **Pipeline de nettoyage reproductible** et adapté aux données du bâtiment.
- **Benchmark de 4 modèles** avec évaluation multicritère (performance, temps, interprétabilité).
- **Approche modulaire** permettant l’intégration de nouveaux modèles.
- **Validation croisée systématique** pour assurer la robustesse.

6.2 Apports opérationnels

- **Prédiction précise** de la consommation énergétique ($R^2 > 0.97$).
- **Outil d'aide à la décision** pour les architectes et ingénieurs en énergie.
- **Optimisation potentielle** des conceptions architecturales pour réduire l'empreinte carbone.
- **Simulation rapide** de scénarios énergétiques.

6.3 Apports environnementaux

- Réduction de la **consommation énergétique** via une modélisation fine.
- Contribution à la **rénovation énergétique** des bâtiments existants.
- Alignement avec les **objectifs de neutralité carbone**.
- Support aux **politiques publiques** d'efficacité énergétique.

7 Limites et difficultés rencontrées

7.1 Limites techniques

- **Taille réduite du dataset** (768 échantillons) limite l'apprentissage profond.
- **Black box** de l'ANN complique l'interprétation des prédictions.
- **Sensibilité au scaling** nécessite une préparation minutieuse des données.
- **Reproductibilité limitée** pour l'ANN due à l'initialisation aléatoire.

7.2 Difficultés méthodologiques

- **Choix des hyperparamètres** pour le SVR et l'ANN demande une expertise.
- **Équilibre performance–temps** à arbitrer selon le contexte d'utilisation.
- **Validation des règles métier** dans le pipeline de nettoyage.
- **Sélection des métriques** appropriées pour l'évaluation.

7.3 Limites des données

- **Variables manquantes** potentiellement influentes (isolation, matériaux, climat).
- **Données synthétiques ou simulées** pouvant limiter la généralisation au réel.
- **Manque de temporalité** (données statiques sans dimension temporelle).
- **Couverture géographique limitée** des bâtiments étudiés.

8 Perspectives d'amélioration et recherches futures

8.1 Améliorations immédiates

- **Ensemble Learning** : Combinaison KNN + ANN pour améliorer robustesse et performance.
- **Feature Engineering** : Création de ratios (surface/volume, compacité/énergie).
- **Cross-Validation avancée** : 10-fold ou Leave-One-Out pour validation plus robuste.
- **Standardisation systématique** pour tous les modèles sensibles au scaling.

8.2 Améliorations à moyen terme

- **Bayesian Optimization** pour l'optimisation automatique des hyperparamètres.
- **Architectures spécialisées** : réseaux résiduels, à attention, ou transformers.
- **Transfer Learning** avec des modèles pré-entraînés sur des données similaires.
- **Modèles hybrides** combinant approches statistiques et deep learning.

8.3 Axes de recherche à long terme

- **Intégration de données externes** : météo, occupation, équipements.
- **Modélisation multi-sorties** simultanée (Heating + Cooling Load).
- **Explicabilité des modèles** (SHAP, LIME) pour l'ANN.
- **Déploiement en temps réel** avec monitoring continu des performances.

— **Modèles adaptatifs** s’ajustant aux nouvelles données sans ré-entraînement complet.

9 Recommandations stratégiques

TABLE 5 – Recommandations selon les cas d’usage

Cas d’usage	Modèle recom-mandé	Justification
Prototypage / explo-ration	KNN	Rapide, interprétable, stable, facile à implémenter
Production – perfor-mance max	ANN	Meilleures métriques, prédiction ultra-rapide, scalable
Environnements régle-mentés	Régression Linéaire ou KNN	Transparence et interprétabilité re-quisies, auditabilité
Systèmes temps réel	ANN	Prédiction en millisecondes, faible latence
Données limitées ou bruitées	SVR	Robustesse aux outliers via kernel RBF
Applications critiques	KNN	Stabilité prouvée, reproductibilité, faible variance
Recherche acadé-mique	ANN	Potentiel d’innovation, flexibilité ar-chitecturale

10 Conclusion du chapitre

Ce chapitre a permis de **confronter les résultats** des trois phases du projet, de **discuter les performances** sous l’angle de la robustesse, de la généralisation et de l’interprétabilité, et de **valider les hypothèses** initiales.

Les modèles développés **répondent aux enjeux de la transition énergétique** en offrant des outils prédictifs précis et adaptables. Le choix du modèle devra néanmoins s’adapter au **contexte d’utilisation**, en arbitrant entre performance, vitesse, et trans-parence.

Les **perspectives identifiées** ouvrent la voie à des améliorations significatives, no-tamment via l’apprentissage ensemble, l’optimisation bayésienne, et l’intégration de don-nées complémentaires. Ces développements pourraient renforcer l’impact du projet dans la lutte contre le changement climatique et la promotion de l’efficacité énergétique.

Perspective finale : Ce travail démontre que l'intelligence artificielle, couplée à une ingénierie des données rigoureuse, peut apporter des solutions concrètes aux défis énergétiques contemporains. La synergie entre expertise technique et conscience environnementale constitue une voie prometteuse pour des villes plus durables.
